

RAPPORT DE MINIPROJET

Module : Data Engineering & Business Intelligence
Année Universitaire : 2024–2025

MEXORA ANALYTICS

Construire un Data Warehouse From Scratch

Réalisé par :

Rahima Gharbil • Manal Souass

Encadré par :

M. Hassan Zili

TABLE DES MATIÈRES

1. Introduction Générale	2
2. Contexte et Analyse des Besoins	2
2.1 Objectifs Métier	2
3. Modélisation Multidimensionnelle (Schéma en Étoile)	3
3.1 Granularité	3
3.2 Architecture du Schéma	3
4. Architecture et Pipeline ETL (Python)	4
4.1 Phase d'Extraction (Extract)	4
4.2 Phase de Transformation (Transform)	4
5. Implémentation du Data Warehouse (PostgreSQL)	5
5.1 DDL et Contraintes	5
5.2 Vues Matérialisées (Reporting Schema)	5
6. Restitution et Business Intelligence (Dashboard)	5
6.1 Vue Globale et Évolution du CA	5
6.2 Top Produits	6
6.3 Analyse des Segments Clients	6
6.4 Taux de Retour	7
6.5 Effet Ramadan	7
7. Conclusion	8

1. Introduction Générale

Dans l'ère numérique actuelle, les données constituent le cœur de la stratégie décisionnelle des entreprises e-commerce. Ce miniprojet, intitulé « Mexora Analytics », a pour objectif principal la conception et la mise en œuvre de A à Z d'un système décisionnel (Business Intelligence) pour une marketplace e-commerce opérant au Maroc.

De la collecte des données hétérogènes et bruitées, en passant par un pipeline de nettoyage complexe (ETL), jusqu'à la restitution visuelle dans un tableau de bord interactif, ce rapport détaille l'ensemble des choix techniques et architecturaux réalisés pour répondre aux exigences de notre encadrant, M. Hassan Zili.

2. Contexte et Analyse des Besoins

Mexora est une marketplace virtuelle qui commercialise diverses catégories de produits (Électronique, Mode, Alimentation) à travers différentes villes du Maroc. Les sources de données de l'entreprise sont hétérogènes (CSV, JSON) et présentent de nombreux problèmes de qualité de données (doublons, erreurs de format, valeurs nulles).

2.1 Objectifs Métier

La direction de Mexora a besoin de suivre les indicateurs suivants pour piloter son activité :

- **Chiffre d'Affaires (CA) TTC** par région, trimestre et catégorie.
- **Identification des produits phares** (« Top 10 »).
- **Analyse des habitudes d'achat** selon les segments clients (Gold, Silver, Bronze).
- **Évaluation de la performance logistique** (taux de retour, délais de livraison).
- **Impact des événements temporels**, notamment l'effet du mois de Ramadan sur les ventes.

3. Modélisation Multidimensionnelle (Schéma en Étoile)

Pour répondre aux problématiques décisionnelles de manière optimale, nous avons opté pour une approche Top-Down (méthodologie Kimball) et modélisé un schéma en étoile.

3.1 Granularité

La table de faits a été conçue à la granularité la plus fine : une ligne = un produit au sein d'une commande. Cela permet une flexibilité totale lors de l'exploration analytique (Drill-down / Roll-up).

3.2 Architecture du Schéma




Figure 1 – Schéma en Étoile du Data Warehouse Mexora

Le schéma s'articule autour de la table de faits FAIT_VENTES, qui contient :

- Des mesures additives : quantite_vendue, montant_ht, montant_ttc, cout_livraison.
- Des mesures semi ou non-additives : delai_livraison_jours, remise_pct.

Elle est reliée à 5 dimensions d'analyse :

- **DIM_TEMP** : Permet l'analyse temporelle, incluant des indicateurs spécifiques comme est_weekend, est_ferie_maroc et periode_ramadan.
- **DIM_PRODUIT** : Gérée avec la méthode SCD de Type 2 (Slowly Changing Dimension) pour historiser les changements de catégories et de prix.
- **DIM_CLIENT** : Contient la démographie et une segmentation RFM dynamique (Gold, Silver, Bronze) gérée en SCD Type 1.
- **DIM_REGION** : Axe d'analyse géographique basé sur le découpage régional marocain.
- **DIM_LIVREUR** : Axe d'analyse de la performance des prestataires logistiques.

4. Architecture et Pipeline ETL (Python)

Le cœur de ce projet repose sur le développement d'un pipeline ETL modulaire et robuste codé entièrement en Python (via la librairie Pandas).




Figure 2 – Architecture Générale du Pipeline ETL (Extract → Transform → Load)

4.1 Phase d'Extraction (Extract)

Les données sont ingérées depuis plusieurs systèmes sources hétérogènes :

- **commandes_mexora.csv** (51 500 lignes) : Fichier transactionnel majeur.
- **clients_mexora.csv** (8 000 lignes) : Données clients brutes.
- **produits_mexora.json** (35 produits) : Référentiel catalogue au format NoSQL.
- **regions_maroc.csv** : Référentiel géographique pour standardisation.

4.2 Phase de Transformation (Transform)

C'est l'étape la plus critique, où plus de 15 règles de gestion et de nettoyage ont été appliquées.

Sur les Commandes :

- Déduplication : Suppression de 1 500 commandes dupliquées (2.9% du dataset).
- Harmonisation géographique : Mapping de 16 variantes de villes (ex : Tnja, TNG, tanger) vers un standard de 10 villes reconnues.
- Anomalies : Suppression des prix nuls (commandes de test) et des quantités négatives.
- Normalisation des Dates : Parsing de formats de dates mixtes.

Sur les Clients :

- Déduplication par Email : Nettoyage des inscriptions multiples.
- Contrôle d'intégrité : Validation des adresses e-mail par Expression Régulière (Regex) et calcul de l'âge (invalidation des âges < 16 ans ou > 100 ans).

- Segmentation : Calcul du CA sur 12 mois pour affecter le statut Gold, Silver ou Bronze.

Bilan du Nettoyage

Nombre initial de commandes : 51 500

Nombre final dans le DWH : 46 080 (~ 10.5% d'anomalies filtrées proprement)

5. Implémentation du Data Warehouse (PostgreSQL)

Les données transformées sont chargées (Phase de Load) dans un Système de Gestion de Bases de Données Relationnelles : PostgreSQL. Trois schémas ont été créés : staging_mexora, dwh_mexora et reporting_mexora.

5.1 DDL et Contraintes

Des scripts SQL robustes ont été développés pour la création de la base de données :

- Mise en place de clés primaires et clés étrangères pour garantir l'intégrité référentielle stricte.
- Création d'Index B-Tree sur les clés étrangères de la table de faits pour optimiser la vitesse d'exécution des requêtes BI.

5.2 Vues Matérialisées (Reporting Schema)

Pour soulager la charge de calcul lors des requêtes du Dashboard, des Vues Matérialisées ont été créées dans le schéma reporting_mexora :

- mv_ca_mensuel_region : Pré-agrégation du CA par mois et par région.
- mv_top_produits_trimestre : Classement pré-calculé des meilleures ventes par trimestre.
- mv_segments_clients : Analyse consolidée des segments Gold / Silver / Bronze.

6. Restitution et Business Intelligence (Dashboard)

Afin de livrer une solution exploitable par la direction de Mexora, nous avons conçu un tableau de bord professionnel, interactif et ergonomique (Dark Mode Premium). Il comporte 6 vues analytiques, accessibles via une navigation latérale unifiée.

6.1 Vue Globale et Évolution du CA

Le dashboard met en avant un CA global généré de 104.9 Millions MAD (+8.2% vs N-1). L'analyse temporelle démontre une croissance soutenue avec la région de Casablanca-Settat comme pôle principal de revenus.



Figure 3 – Dashboard : Vue d'ensemble des KPIs (CA, Commandes, Panier Moyen, Clients Actifs)

La page « Évolution du CA » permet une comparaison mois par mois entre l'année sélectionnée (2024) et l'année précédente (2023), avec des filtres dynamiques sur le trimestre et la ville.



Figure 4 – Dashboard : Évolution mensuelle du Chiffre d'Affaires (comparaison N / N-1)

6.2 Top Produits

La vue « Top Produits » affiche un classement horizontal des 10 meilleurs produits par CA sur la période et la ville sélectionnées. La domination de l'iPhone 16 Pro 256Go et du MacBook Air M3 confirme la prédominance de la catégorie Électronique.




Figure 5 – Dashboard : Top 10 Produits par Chiffre d'Affaires

6.3 Analyse des Segments Clients

Notre modèle de segmentation démontre que bien que le segment Bronze soit le plus peuplé en volume, le segment Gold (clients générant > 15K MAD/an) rapporte un panier moyen significativement supérieur (15 K MAD vs 2 K MAD pour Bronze), constituant le cœur de rentabilité de l'entreprise.



Figure 6 – Dashboard : Répartition du CA et commandes par segment clients (Gold / Silver / Bronze)

6.4 Taux de Retour

L'analyse des retours par catégorie révèle des alertes importantes. Le code couleur appliqué (vert < 3%, orange 3-5%, rouge > 5%) permet d'identifier immédiatement les catégories problématiques.



Figure 7 – Dashboard : Taux de retour par catégorie de produit

La catégorie Mode présente un taux de retour critique de 6.1%, dépassant le seuil d'alerte fixé à 5%. Cette situation nécessite une action corrective prioritaire (amélioration des fiches produits, politique de retour clarifiée).

6.5 Effet Ramadan

L'analyse corrélée à la dimension temps prouve un effet Ramadan exceptionnel. Les ventes alimentaires enregistrent un pic massif lors du mois sacré, avec un indice de performance de 150% (+50% vs le reste de l'année).




Figure 8 – Dashboard : Analyse de l'Effet Ramadan sur les ventes alimentaires

Ce résultat constitue un levier stratégique majeur : une anticipation des stocks alimentaires et des campagnes promotionnelles ciblées pendant Ramadan permettrait d'amplifier davantage ce pic de performance.

7. Conclusion

Ce projet nous a permis d'appliquer les concepts théoriques de la Business Intelligence sur un cas d'usage concret, complexe et proche de la réalité du monde professionnel marocain. Nous avons pu démontrer notre capacité à maîtriser toute la chaîne de valeur de la donnée :

1. Penser et architecturer un modèle en étoile adapté au besoin métier.
2. Traiter les données de façon algorithmique (Python / Pandas).
3. Assurer le stockage structuré et intègre (PostgreSQL, schéma en étoile).
4. Créer de la valeur par la visualisation dynamique et interactive.

Nous tenons à remercier notre encadrant, M. Hassan Zili, pour ses directives et la qualité de ce module qui constitue un pilier majeur de notre formation de futurs ingénieurs de la donnée.