

Modélisation du Data Warehouse — Mexora Analytics

| Document de justification des choix architecturaux du Data Warehouse Mexora.

1. Analyse des Besoins Décisionnels (Top-Down)

Requêtes-types formalisées

Réf.	Mesure analysée	Dimensions	Filtre
R1	CA (montant TTC)	Région, catégorie produit, trimestre	Statut = livré
R2	Qté vendue + montant TTC	Produit, mois, segment client	Année 2024
R3	Panier moyen (TTC / nb commandes)	Segment client Gold/Silver/Bronze	Clients actifs 12 mois
R4	Taux de retour (%)	Catégorie produit, région	Livré + retourné
R5	Volume vendu + CA moyen journalier	Période Ramadan vs hors, catégorie	Alimentation 2022-2024
R6	Délai moyen de livraison	Livreur, zone de couverture, mois	Livré + retourné
R7	Nb clients distincts + CA	Ville, canal d'acquisition	Commandes livrées

2. Granularité de la Table de Faits

Choix : 1 ligne = 1 ligne de commande

Chaque ligne de `FAIT_VENTES` représente exactement **1 produit vendu dans 1 commande**, à une date donnée, par un client identifié, dans une région, avec un livreur.

Justification

- **Niveau de détail maximal** : permet de répondre à toutes les requêtes analytiques sans perte d'information
- **Flexibilité** : les agrégations (par mois, trimestre, région, catégorie) sont calculées dynamiquement via les jointures dimensions
- **Conformité Kimball** : correspond au grain recommandé pour les tables de faits transactionnelles
- **Traçabilité** : chaque vente peut être retracée jusqu'à la commande source

3. Classification des Mesures

Mesure	Type	Justification
<code>quantite_vendue</code>	Additive	Sommable sur toutes les dimensions (temps, produit, client, région, livreur)
<code>montant_ht</code>	Additive	CA hors taxes — sommable partout
<code>montant_ttc</code>	Additive	CA TTC — sommable partout
<code>cout_livraison</code>	Additive	Coût de livraison — sommable partout
<code>delai_livraison_jours</code>	Semi-additive	Non sommable sur le temps — utiliser <code>AVG()</code> . Le délai moyen d'un mois $\neq \Sigma$ délais
<code>remise_pct</code>	Non-additive	Pourcentage — recalcul requis : $\frac{\text{remise_totale}}{\text{CA_total}} \times 100$

4. Gestion des Slowly Changing Dimensions (SCD)

Cas 1 — SCD Type 2 : `DIM_PRODUIT` (changement de catégorie)

Scénario :

Le produit "iPhone 16 Pro" était classé dans la catégorie "Téléphones" jusqu'en mars 2024. Suite à une réorganisation du catalogue, il passe dans "Smartphones" en mars 2024.

Choix : SCD Type 2 — Historisation complète

Justification :

- Les ventes **antérieures** à mars 2024 restent classées dans "Téléphones"
- Les ventes **postérieures** sont classées dans "Smartphones"
- Garantit la **cohérence historique** des analyses par catégorie

Implémentation :

id_produit_sk	id_produit_nk	categorie	date_debut	date_fin	est_actif
1	P001	Téléphones	2024-01-01	2024-03-14	<code>false</code>
2	P001	Smartphones	2024-03-15	9999-12-31	<code>true</code>

- `date_debut` / `date_fin`: plage de validité de la version
- `date_fin = 9999-12-31`: version courante active
- `est_actif`: flag booléen pour filtrage rapide

Cas 2 — SCD Type 1: `DIM_CLIENT` (changement de segment)

Scénario :

Un client était "Silver" au T1 2024 (CA 12 mois = 7 200 MAD).


Après des achats importants, il passe "Gold" au T2 2024 (CA 12 mois = 18 500 MAD).

Choix : SCD Type 1 — Mise à jour directe (écrasement)


Justification :

- Le segment est une **mesure dérivée recalculée** à chaque exécution du pipeline ETL
- L'analyse porte toujours sur le **segment actuel** du client
- Le segment reflète le comportement des **12 derniers mois glissants**
- L'historique des achats dans `FAIT_VENTES` permet de recalculer tout segment passé si nécessaire

5. Schéma en Étoile (ERD)



nom_produit	FK id_client_sk	nom_complet
categorie	FK id_region	tranche_age
sous_categorie	FK id_livreur	sexe
marque		segment_client
prix_unitaire	quantite_vendue	canal_acq
fournisseur	montant_ht	(SCD Type 1)
date_debut	montant_ttc	
date_fin	cout_livraison	
est_actif	delai_livraison	
(SCD Type 2)	remise_pct	
	statut_commande	



6. Requêtes Analytiques SQL

Q1 — CA par région avec évolution 12 mois

```

sql

SELECT r.region_admin, t.annee, t.mois,
       SUM(f.montant_ttc) AS ca_ttc
FROM   dwh_mexora.fait_ventes f
JOIN   dwh_mexora.dim_temps  t ON f.id_date  = t.id_date
JOIN   dwh_mexora.dim_region r ON f.id_region = r.id_region
WHERE  f.statut_commande = 'livré'
GROUP BY r.region_admin, t.annee, t.mois
ORDER BY t.annee DESC, t.mois DESC, ca_ttc DESC;

```

Q2 — Top 10 produits à Tanger par trimestre

```

sql

```

```

SELECT t.trimestre, p.nom_produit, p.categorie,
       SUM(f.montant_ttc) AS ca_total
FROM   dwh_mexora.fait_ventes f
JOIN   dwh_mexora.dim_temps   t ON f.id_date   = t.id_date
JOIN   dwh_mexora.dim_produit p ON f.id_produit = p.id_produit_sk
JOIN   dwh_mexora.dim_region  r ON f.id_region = r.id_region
WHERE  r.ville = 'Tanger'
      AND f.statut_commande = 'livré'
GROUP BY t.trimestre, p.nom_produit, p.categorie
ORDER BY ca_total DESC
LIMIT 10;

```

Q3 — Panier moyen par segment client

```

sql

SELECT c.segment_client,
       COUNT(DISTINCT f.id_vente)           AS nb_commandes,
       ROUND(SUM(f.montant_ttc)
             / COUNT(DISTINCT f.id_vente), 2) AS panier_moyen
FROM   dwh_mexora.fait_ventes f
JOIN   dwh_mexora.dim_client  c ON f.id_client = c.id_client_sk
WHERE  f.statut_commande = 'livré'
      AND c.est_actif = TRUE
GROUP BY c.segment_client
ORDER BY panier_moyen DESC;

```

Q4 — Taux de retour par catégorie de produit

```

sql

SELECT p.categorie,
       COUNT(*) FILTER (WHERE f.statut_commande = 'retourné') AS nb_retours,
       COUNT(*)                                               AS nb_total,
       ROUND(
         COUNT(*) FILTER (WHERE f.statut_commande = 'retourné')
         * 100.0 / NULLIF(COUNT(*), 0), 2)                    AS taux_retour_pct
FROM   dwh_mexora.fait_ventes f
JOIN   dwh_mexora.dim_produit p ON f.id_produit = p.id_produit_sk
GROUP BY p.categorie
ORDER BY taux_retour_pct DESC;

```

Q5 — Effet Ramadan sur les ventes alimentaires

```

sql

```

```
SELECT t.periode_ramadan,  
       ROUND(AVG(f.montant_ttc), 2) AS ca_moyen_par_vente,  
       SUM(f.quantite_vendue)      AS volume_total  
FROM   dwh_mexora.fait_ventes f  
JOIN   dwh_mexora.dim_temps   t ON f.id_date   = t.id_date  
JOIN   dwh_mexora.dim_produit p ON f.id_produit = p.id_produit_sk  
WHERE  p.categorie = 'Alimentation'  
      AND f.statut_commande = 'livré'  
GROUP BY t.periode_ramadan;
```